▶ 1분 미리보기

Chapter 6. 조직의 비용 보고 통제하기

쓴 만큼 보고, 넘치면 막는다 (Claude Code v2.1.319, 2026-11-08 리허설 검증)

Oh, Junseok
Sr. Solutions Architect
AWS Korea

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

기대 주제 FinOps, 그리고 비용 가시화

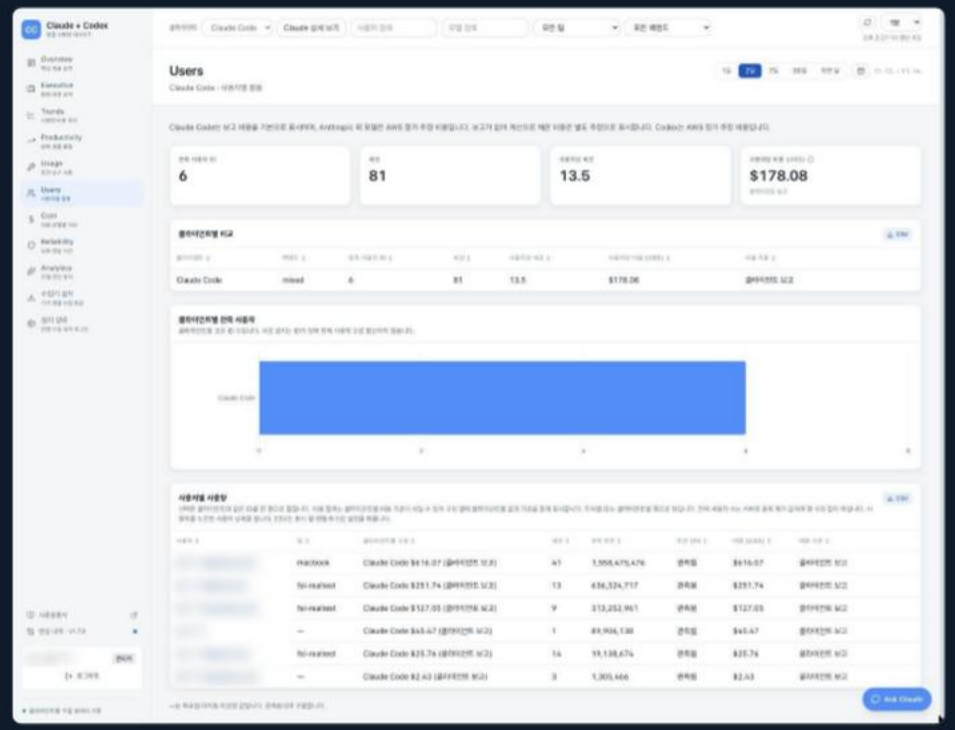
사전 설문 결과로 정한 이 챕터의 목표

PRE-SURVEY

26명

참가 확정자 **142명 중 26명**이 FinOps(모델 라우팅, 토큰 메터링, OTel 대시보드)를 기대 주제로 골랐습니다.

자유 의견에도 조직 사용 비용의 가시화, 사내 토큰 배분 정책을 묻는 질문이 있었습니다. 이 챕터는 OTel로 모은 사용량을 대시보드로 보고, 한도로 막는 법입니다.



OTel로 모은 사용량, ccdash Users 화면 (랩 환경, 식별자 가림)

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

강의와 데모, 그리고 랩

계측, 계약 단가, 게이트웨이 지출 한도의 순서

CHAPTER 06

조직의 비용 통제

OTel 대시보드, modelPricing, 게이트웨이 지출 한도

강의와 데모

LAB / Ch6 Lab

TASK 01부터 03, 선택 TASK 04

텔레메트리 경로, 그룹별 모델 정책, 지출 한도, 계약 단가

강의 뒤 바로

MORE

더 알아보기

자주 묻는 세부 내용은 마지막에 모아 둡니다

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

CHAPTER 06

조직의 비용 통제

쓴 만큼 보고, 넘치면 막는다

01
Bedrock에서 비용을 보는 법

02
OTel 대시보드

03
modelPricing과 AWS 쪽 도구

04
Claude Apps Gateway (참가자 실습)

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Bedrock 가시성, 콘솔과 자체 계측뿐

셋업별 비용 관리 방법

이 워크숍
Amazon Bedrock

구독
Claude Team, Enterprise

API
Claude Console

Amazon Bedrock

지출 보기	AWS 청구 콘솔
지출 한도	AWS 예산 도구
사용자별	IAM principal, 태그(CUR 2.0), OTel, 게이트웨이

사용자별로 보려면 클라우드 콘솔만으로는 부족하고, 직접 설치한 계측이 필요합니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

BEDROCK REALITY

Bedrock에는 Analytics 대시보드가 없습니다

계측을 설치해야 보이고, 설치하지 않은 사람은 잡히지 않습니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

정책으로 켜는 OTel

managed settings env 한 블록이면 모두에게

STEP 1 **정책으로 켜면 모두가 계측됩니다**

OTel(OpenTelemetry)은 켜야 생깁니다. **managed settings의 env 한 블록**으로 배포하면 사용자가 끌 수 없고, 빠지는 사람이 없습니다.



● 관리자가 강제 ● Claude Code ● 수집기 ● 보는 곳

managed-settings.json (env)

OTel을 정책으로 켜기

```
"env": {
  "CLAUDE_CODE_ENABLE_TELEMETRY": "1",
  "OTEL_METRICS_EXPORTER": "otlp",
  "OTEL_LOGS_EXPORTER": "otlp",
  "OTEL_EXPORTER_OTLP_PROTOCOL":
"http/protobuf",
  "OTEL_EXPORTER_OTLP_ENDPOINT":
    "https://otel.corp.example.internal",
  "OTEL_RESOURCE_ATTRIBUTES":
    "department=platform,team.id=core"
}
```

엔드포인트는 예시 주소입니다.

- CLAUDE_CODE_ENABLE_TELEMETRY: 1
- managed settings로 배포
- 설치하지 않은 사람이 없게

‹ 1 / 5 ›

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

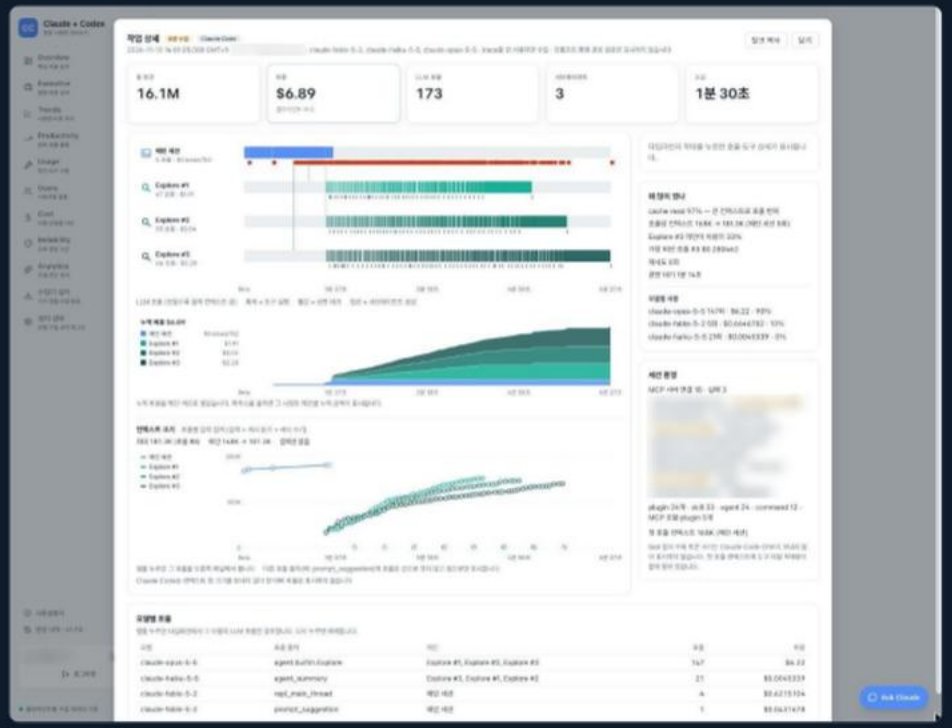
이틀간 우리가 쓴 토큰

DEMO, 강사 대시보드 (URL은 현장 안내)

DEMO

화면에는 참가자 ID만 표시합니다. 회사별 사용량은 노출하지 않습니다.

1	랩 환경은 Day 1부터 OTel 수집 중 (참가 안내문 고지)
2	전체 토큰, 비용 추이, Capstone 구간 피크 확인
3	모델별, 도구별 분포, 캐시 적중률
4	내 참가자 ID로 내 사용량 찾기
5	가장 비용이 컸던 패턴을 Ch5의 원리로 해석



작업 상세: 레인별 호출, 누적 비용, 비용이 커진 이유 (식별자 가림)

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

추정 비용을 청구서에 가깝게

계약 단가로 보여 주는 modelPricing

managed-settings.json

```
{
  "modelPricing": {
    "multiplier": 0.9
  }
}
# /usage, Total cost … at your organization's
configured rates
```

- managed settings에서만 유효 (v2.1.242+)
- multiplier가 1보다 작으면 할인, 크면 할증
- 모델별 단가는 overrides로
- **표시만 바꿈, 청구는 그대로**
- 숫자는 계약 단가를 입력



실제 정산은 AWS 청구서입니다. modelPricing은 /usage와 대시보드의 숫자를 청구서에 가깝게 맞추는 표시 설정입니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

AWS 쪽에서 보는 비용

Claude Code 계측과 별개로 계정에서 보이는 것, 둘을 대사

01

Application inference profile 태그

Ch2의 modelOverrides로 팀별 경로를 만들고 Cost Explorer에서 봅니다.

02

AWS Budgets

계정, 태그 단위 예산 알람

03

전용 AWS 계정

Claude Code 비용을 계정 경계로 분리 (공식 권장)

04

TPM 쿼터

라이브 교육 같은 동시 사용 급증은 사전 증액

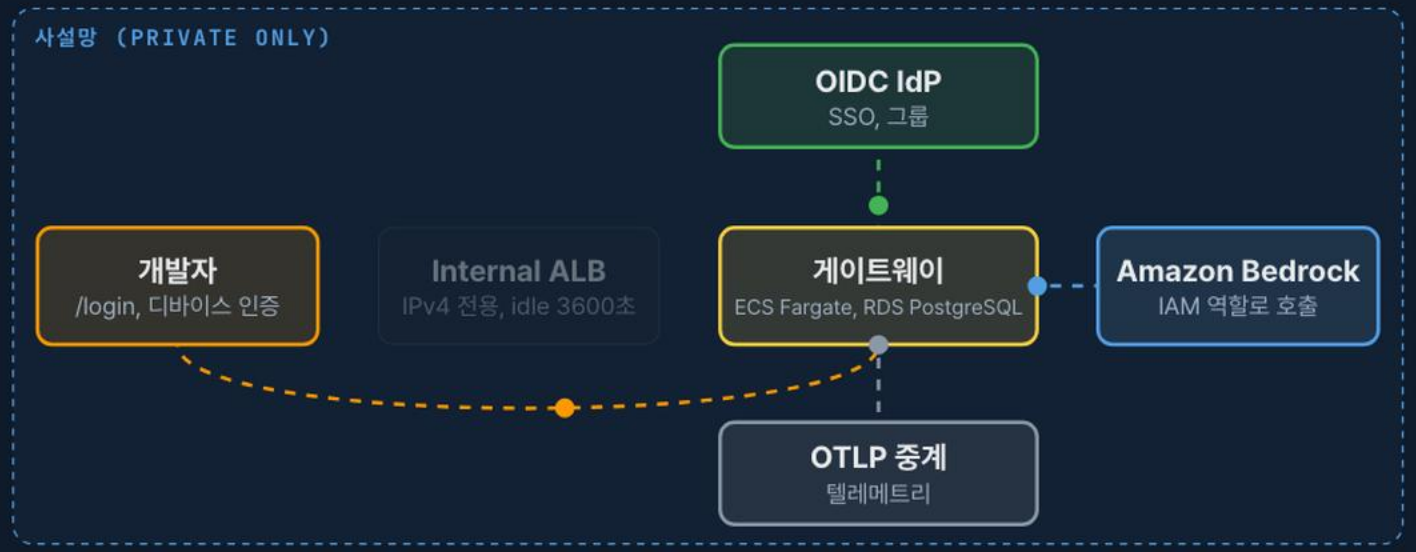
© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Bedrock 앞단의 게이트웨이

Claude Apps Gateway, 공식 구성과 이번 랩 구성

OVERVIEW **SSO, 그룹 정책, 지출 한도를 한곳에서**

Claude Apps Gateway는 Bedrock 앞단에 **직접 운영하는** 게이트웨이로, SSO(Single Sign-On) 로그인, IdP(사내 인증 시스템) 그룹별 모델과 정책, 사용자별 지출 한도, OTLP 중계를 맡습니다.



개발자 · 네트워크와 Bedrock · 게이트웨이 · IdP · 텔레메트리 중계

claude 바이너리에 포함

게이트웨이 실행

```
claude gateway --config gateway.yaml
```

별도 제품 설치가 아니라 **claude 바이너리의 하위 명령**입니다.

- SSO 로그인
- IdP 그룹별 모델과 정책
- 사용자별 지출 한도
- OTLP 중계

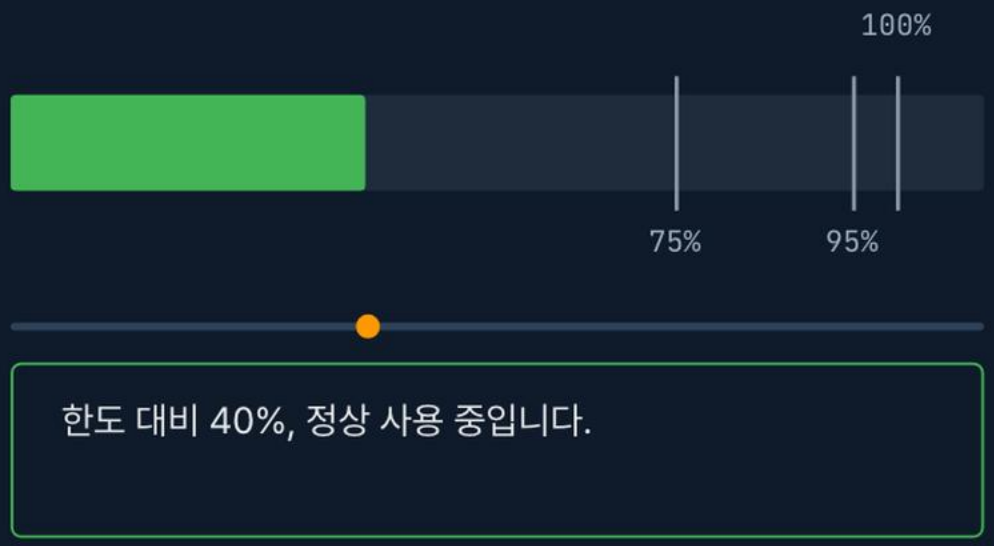
‹ 1 / 6 ›

ALB · ECS Fargate · RDS · Bedrock · Route 53 · Cognito · CloudFront

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

사용자별 지출 한도를 실시간으로

지출 한도의 범위, 기간, 초과 시 동작



한도 대비 사용액은 설명용 예시입니다.

범위	user (OIDC sub), rbac_group, organization 그룹, 조직 한도는 1인당 기본값
기간	daily, weekly, monthly (UTC 기준 리셋) 기간별로 각각 적용
초과 시	429 billing_error + 리셋 시각 75%, 95%에서 사전 경고
단가	pricing.overrides, 목록가, 미지 모델 $5/$25 순 추정치, 정산은 AWS
설정	Admin API POST /v1/organizations/spend_limits gateway.yaml이 아님

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

운영 전에 정할 두 가지

기본값이 금융권 기대와 다를 수 있습니다

저장소 장애 시

설정 바꿔 보기 `fail-open (기본값)`

> 저장소 장애 중에도 요청은 통과하고 경고 로그만 남습니다.
> 그동안의 지출은 계측되지 않을 수 있습니다.

- 기본은 fail-open: 요청 통과, 경고 로그
- enforcement.fail_closed_on_error: true면 차단
- 추론 중단과 미계측 지출 중 선택

개인정보

- principal_emails 테이블에 이메일, 이름, 그룹 저장
- 기본 90일 보존 (identity_retention_days)
- 퇴사, 열람 요청 시 해당 행 삭제
- spend, audit은 OIDC sub만 참조

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

그룹 한도와 사용자 한도, 누가 이기나

QUICK CHECK, 손을 들어 답해 주세요

standard-users 그룹 한도가 $50/일인데 bob에게만 1센트 사용자 한도를 걸면?

A 그룹 한도 $50이 우선한다

B 사용자 한도가 우선해 다음 요청부터 429로 막힌다

C 진행 중인 응답까지 즉시 끊긴다

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

텔레메트리는 어디로 가는가

LAB, Chapter 6 TASK 01

1 settings.json의 OTEL_* 환경 변수 읽기

2 otelcol, fanout 타이머 active 확인

3 scrub_logs: 내보내기 전 프롬프트 본문 삭제 규칙 찾기

4 exporters에서 CloudWatch + 중앙 대시보드 이중 전송 확인

Hands-on Lab 포털에서 Chapter 6 TASK 01을 엽니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

모델 정책과 지출 한도

LAB, 게이트웨이 실습 Chapter 6 TASK 02부터 03까지

1	use_gateway, alice 로그인, /model에 Opus 포함, /usage Spend limit 확인
2	bob으로 재로그인, Opus 없음, 질문 1개로 지출 기록
3	Terminal 2: Admin API로 bob 조회, 사용자 한도 1센트
4	bob 다음 요청이 지출 한도 메시지로 거절
5	한도 DELETE, 그룹 한도 복원, use_bedrock_direct

각자 계정의 게이트웨이로 진행합니다. Hands-on Lab 포털, Chapter 6 TASK 02부터 03. 게이트웨이 장애 팀은 강사 화면을 봅니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

내 계정에 비용 설정 적용

선택 LAB, Chapter 6 선택 TASK 04

1	managed settings에 modelPricing.multiplier 병합
2	/usage에서 configured rates 표시 확인
3	대시보드에서 적용 전후 내 사용량 비교
4	백업으로 원복

각자 Bedrock 직결로 진행합니다. Hands-on Lab 포털, Chapter 6 선택 TASK 04.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

자주 받는 질문

더 알아보기, OTel 지표, 이상 징후, Admin API

1
OTel 지표 모음

2
이상 징후 패턴

3
Admin API로 한도 운영

대시보드의 숫자는 어디서 오나

지표	속성	용도
`token.usage`	type: input, output, cacheRead, cacheCreation	캐시 효율, 모델별 사용량
`cost.usage`	model	추정 비용 (정산은 AWS)
`session.count`	user, team 속성	활성 사용자
`lines_of_code.count`	type: added, removed	생산성 지표
`commit.count`, `pull_request.count`	없음	산출물
`active_time.total`	없음	실제 사용 시간

지표 이름 앞에는 모두 `claude_code.` 접두사가 붙습니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

보고, 막기

Chapter 6 Key Takeaways

01

Bedrock은 Analytics가 없다.
OTel을 정책으로 켠다

02

modelPricing으로 계약 단가 표시,
정산은 AWS와 대사

03

게이트웨이: SSO, 그룹 정책, 지출 한도, 사설망 전용

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Thank You

다음은 Capstone 쇼케이스와 Closing입니다. 질문은 Slack #20261116-claude-code-workshop-for-fsi 채널에 언제든 편하게 남겨 주세요.

수고하셨습니다!

← 목차로 돌아가기

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.