▶ 1분 미리보기

Chapter 6. 조직의 비용 보고 통제하기

쓴 만큼 보고, 넘치면 막는다 (Claude Code v2.1.319, 2026-11-08 리허설 검증)

Oh, Junseok
Sr. Solutions Architect
AWS Korea

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

기대 주제 FinOps, 그리고 비용 가시화

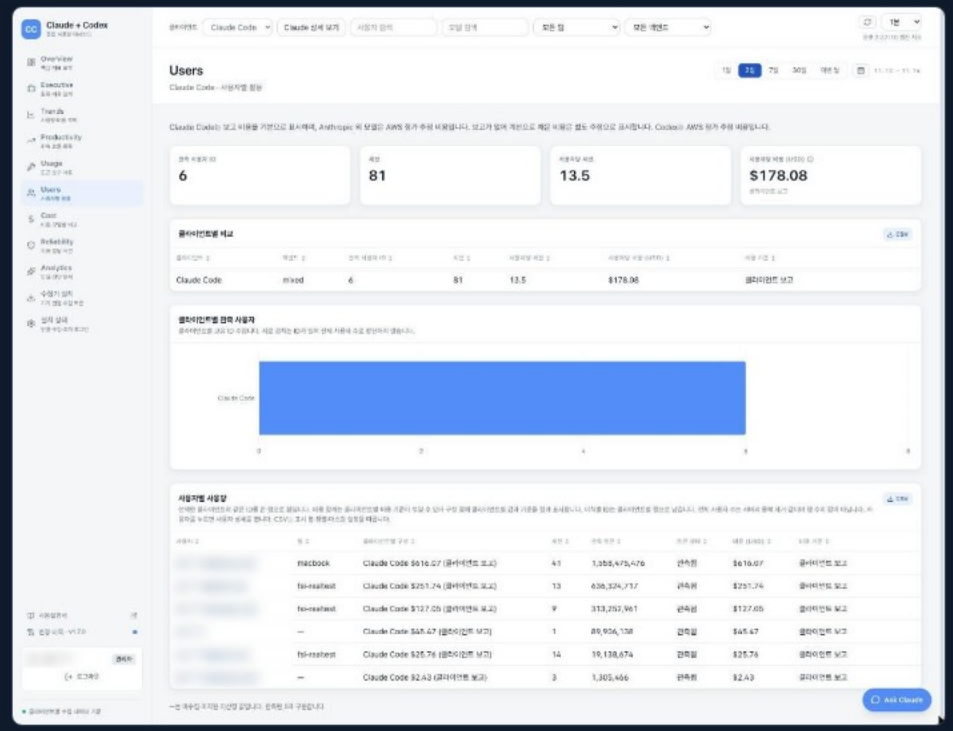
사전 설문 결과로 정한 이 챕터의 목표

PRE-SURVEY

26명

참가 확정자 **142명 중 26명**이 FinOps(모델 라우팅, 토큰 메터링, OTel 대시보드)를 기대 주제로 골랐습니다.

자유 의견에도 조직 사용 비용의 가시화, 사내 토큰 배분 정책을 묻는 질문이 있었습니다. 이 챕터는 OTel로 모은 사용량을 대시보드로 보고, 한도로 막는 법입니다.



OTel로 모은 사용량, ccdash Users 화면 (랩 환경, 식별자 가림)

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

강의와 데모, 그리고 랩

계측, 계약 단가, 게이트웨이 지출 한도의 순서

CHAPTER 06

조직의 비용 통제

OTel 대시보드, modelPricing, 게이트웨이 지출 한도

강의와 데모

LAB / Ch6 Lab

TASK 01부터 03, 선택 TASK 04

텔레메트리 경로, 그룹별 모델 정책, 지출 한도, 계약 단가

강의 뒤 바로

MORE

더 알아보기

자주 묻는 세부 내용은 마지막에 모아 둡니다

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

CHAPTER 06

조직의 비용 통제

쓴 만큼 보고, 넘치면 막는다

01
Bedrock에서 비용을 보는 법

02
OTel 대시보드

03
modelPricing과 AWS 쪽 도구

04
Claude Apps Gateway (참가자 실습)

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Bedrock 가시성, 콘솔과 자체 계측뿐

셋업별 비용 관리 방법

이 워크숍
Amazon Bedrock

구독
Claude Team, Enterprise

API
Claude Console

Claude Console

지출 보기	Console Usage
지출 한도	Workspace limit
사용자별	Claude Code Analytics API

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

BEDROCK REALITY

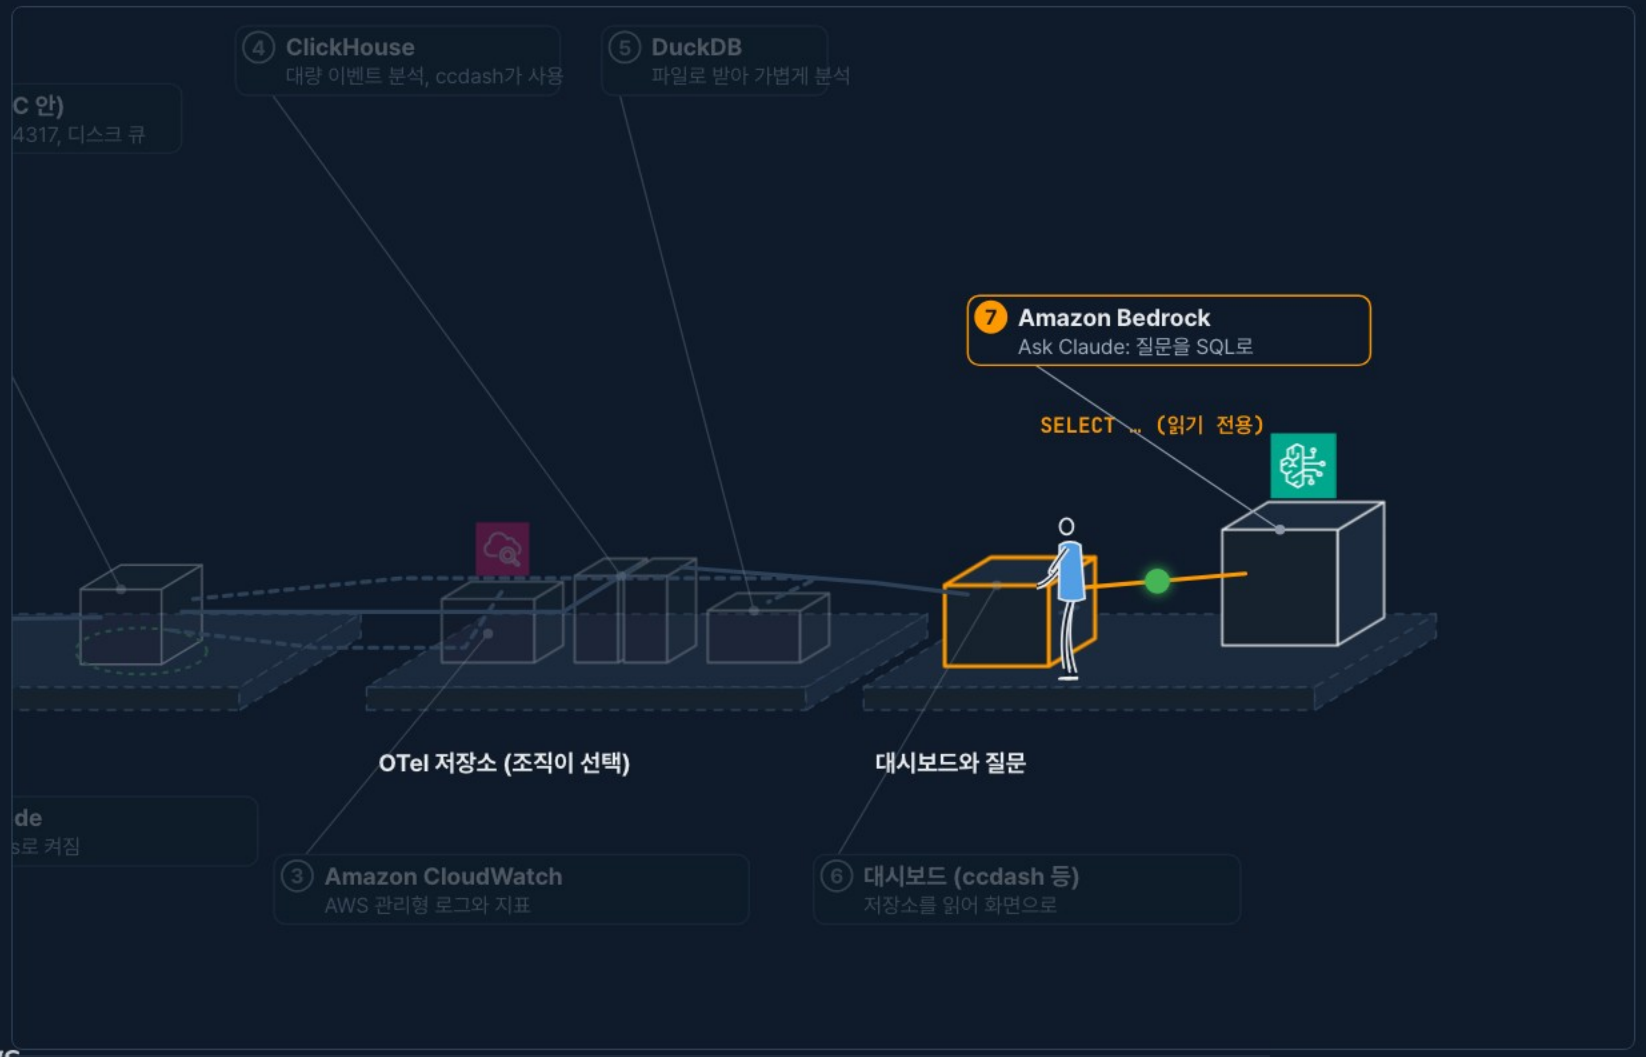
Bedrock에는 Analytics 대시보드가 없습니다

계측을 설치해야 보이고, 설치하지 않은 사람은 잡히지 않습니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

프롬프트 하나가 대시보드 숫자가 되기까지

요청 하나가 남기는 기록의 길 (랩 환경 기준)



7 질문

Ask Claude, 말로 묻고 표로 받기

```
CLAUDE_CODE_ENABLE_TELEMETRY=1
OTEL_METRICS_EXPORTER=otlp
OTEL_LOGS_EXPORTER=otlp
OTEL_EXPORTER_OTLP_PROTOCOL=grpc
OTEL_EXPORTER_OTLP_ENDPOINT=
  http://localhost:4317
# 이벤트 claude_code.api_request
#   model, input_tokens, output_tokens,
#   cache_read_tokens,
cost_usd, duration_ms
# 프롬프트 본문: 기본 미전송 (길이만)
```

"오류가 많은 도구는?"처럼 물으면 Bedrock의 Claude가 **읽기 전용 SQL**로 조회하고, 표와 해석으로 답합니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

정책으로 켜는 OTel

managed settings env 한 블록이면 모두에게

LAB **랩 환경은 두 곳으로 보냅니다**

이번 랩 환경은 **otelcol**이 받아 내보내기 전에 **scrub_logs**로 프롬프트 본문을 지우고, **CloudWatch와 중앙 대시보드**로 이중 전송합니다.



관리자가 강제 · Claude Code · 수집기 · 보는 곳

TASK 01에서 확인

랩 환경

```
# settings.json의 OTEL_* 환경 변수
# otelcol, fanout 타이머 active
# scrub_logs: 프롬프트 본문 삭제 규칙
# exporters: CloudWatch + 중앙 대시보드
```

프롬프트 본문을 **내보내기 전에 지우는** 규칙이 금융권 운영의 기본입니다.

- otelcol, fanout 타이머 active
- scrub_logs: 내보내기 전 프롬프트 본문 삭제
- exporters: CloudWatch + 중앙 대시보드

‹ 5 / 5 ›

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

OTel이 보내는 것, 보내지 않는 것

지표와 이벤트는 가고, 본문은 기본으로 남는다

지표 (기본 1분마다)

숫자로 쌓이는 8가지

- `token.usage` 입력, 출력, 캐시 읽기, 캐시 쓰기
- `cost.usage` 추정 비용 (USD)
- `session.count`, `active_time.total`
- `lines_of_code.count`, `commit.count`, `pull_request.count`
- `code_edit_tool.decision` 편집 허용, 거부

이벤트 (기본 5초마다)

한 건씩 남는 기록

- `api_request` 모델, 토큰, cost_usd, 걸린 시간
- `tool_result` 도구 이름, 성공 여부, 걸린 시간
- `tool_decision` 허용, 거부와 그 출처
- `user_prompt` 프롬프트 **길이**
- `api_error` 상태 코드, 재시도

기본으로 보내지 않음

켜야만 나가는 내용

- 프롬프트 본문 `OTEL_LOG_USER_PROMPTS`
- 도구 인자 `OTEL_LOG_TOOL_DETAILS`
- 응답 본문 `OTEL_LOG_ASSISTANT_RESPONSES`
- API 원문 `OTEL_LOG_RAW_API_BODIES`

금융권 운영은 이 스위치를 **끈 채로** 두고, 수집기에서 한 번 더 지웁니다.

모든 지표 이름 앞에는 `claude_code.`가 붙습니다. 비용 지표는 추정치이고, 정산은 AWS 청구서가 기준입니다.

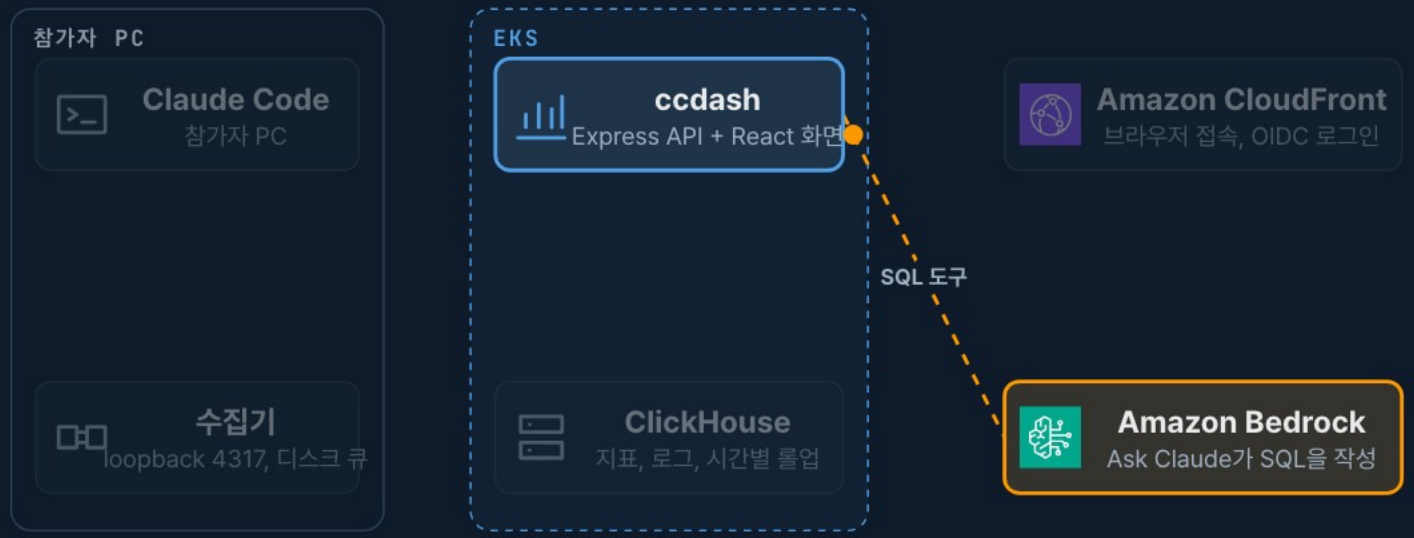
aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

ccdash, 워크숍 사용량 대시보드

OTel을 받아 쌓고, 화면과 질문으로 보여 주는 구조

STEP 4 **Ask Claude: 말로 묻고 표로 받기**

질문을 하면 Bedrock의 Claude가 **SQL을 작성해 읽기 전용으로** 조회하고, 표와 해석, 데이터의 한계까지 함께 답합니다.



예시 질문

Ask Claude

> 지난 2일 동안 오류가 가장 많은
> 도구 3개와 오류율을 표로 보여줘

답의 숫자는 **관측값**입니다. 도구 품질이나 사람의 생산성 평가에 쓰지 않습니다.

- 인증된 사용자만 사용
- 읽기 전용 ClickHouse 세션
- 답에 쿼리와 커버리지 한계 표시

● Claude Code, Bedrock ● 수집기 ● 저장, API ● 접속

‹ 5 / 5 ›

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

ccdash 화면 둘러보기

스크롤하고, 눌러 보면 보이는 것들 (리허설 데이터, 식별자 가림)

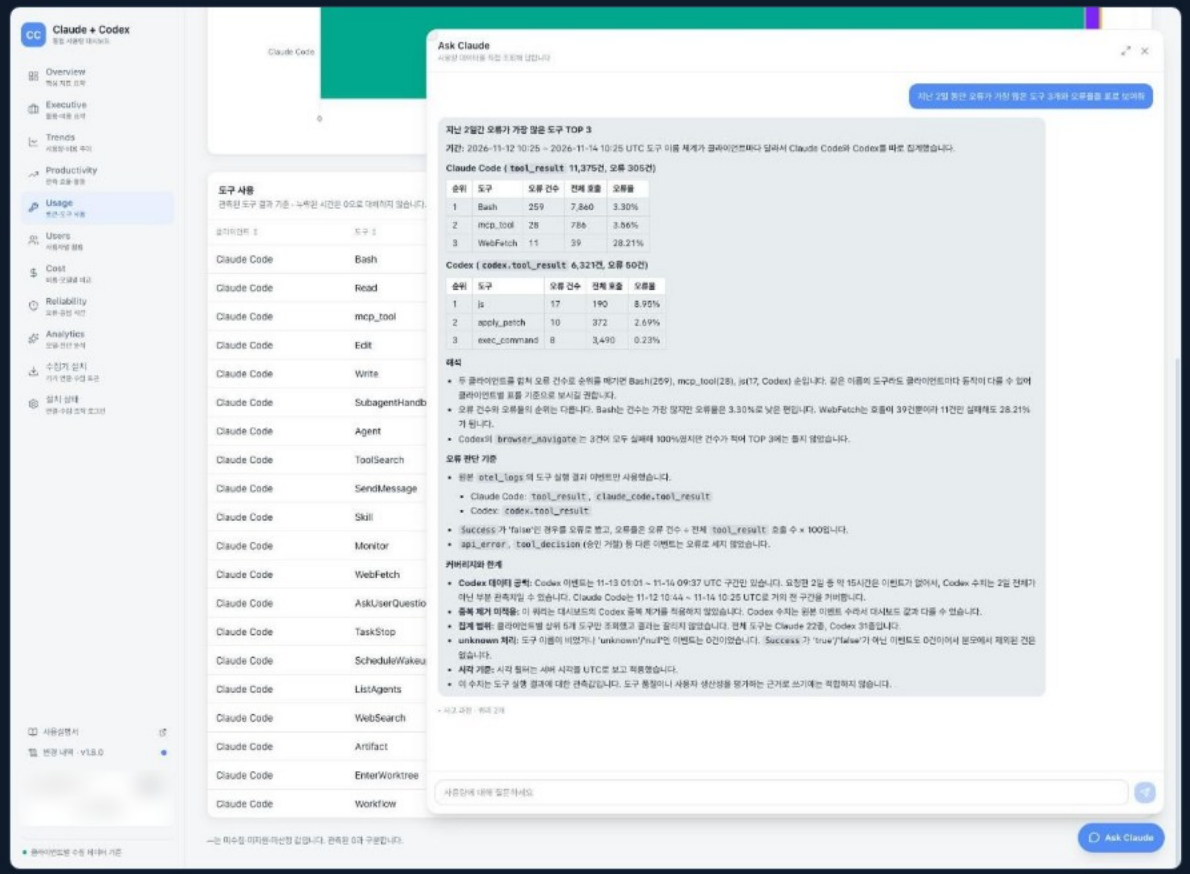
Overview
추이와 모델별 사용량

Usage
도구별 호출과 오류율

Users
작업 목록, 비용 높은 순

Cost
모델, effort, 캐시 구성

Ask Claude
말로 묻고 표로 받기



질문 하나에 표, 해석, 판단 기준, 데이터의 한계까지 함께 돌아옵니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

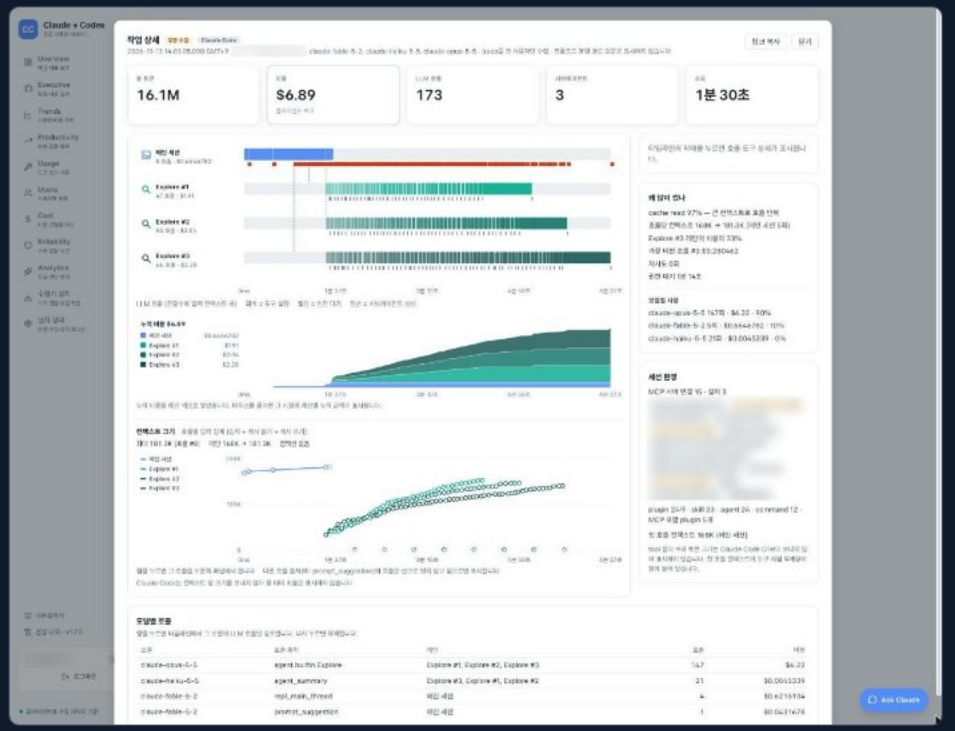
이틀간 우리가 쓴 토큰

DEMO, 강사 대시보드 (URL은 현장 안내)

DEMO

화면에는 참가자 ID만 표시합니다. 회사별 사용량은 노출하지 않습니다.

1	랩 환경은 Day 1부터 OTel 수집 중 (참가 안내문 고지)
2	전체 토큰, 비용 추이, Capstone 구간 피크 확인
3	모델별, 도구별 분포, 캐시 적중률
4	내 참가자 ID로 내 사용량 찾기
5	가장 비용이 컸던 패턴을 Ch5의 원리로 해석



작업 상세: 레인별 호출, 누적 비용, 비용이 커진 이유 (식별자 가림)

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

추정 비용을 청구서에 가깝게

계약 단가로 보여 주는 modelPricing

managed-settings.json

```
{
  "modelPricing": {
    "multiplier": 0.9
  }
}
# /usage, Total cost … at your organization's
configured rates
```

- managed settings에서만 유효 (v2.1.242+)
- multiplier가 1보다 작으면 할인, 크면 할증
- 모델별 단가는 overrides로
- **표시만 바꿈, 청구는 그대로**
- 숫자는 계약 단가를 입력



실제 정산은 AWS 청구서입니다. modelPricing은 /usage와 대시보드의 숫자를 청구서에 가깝게 맞추는 표시 설정입니다.

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

AWS 쪽에서 보는 비용

Claude Code 계측과 별개로 계정에서 보이는 것, 둘을 대사

01

Application inference profile 태그

Ch2의 modelOverrides로 팀별 경로를 만들고 Cost Explorer에서 봅니다.

02

AWS Budgets

계정, 태그 단위 예산 알람

03

전용 AWS 계정

Claude Code 비용을 계정 경계로 분리 (공식 권장)

04

TPM 쿼터

라이브 교육 같은 동시 사용 급증은 사전 증액

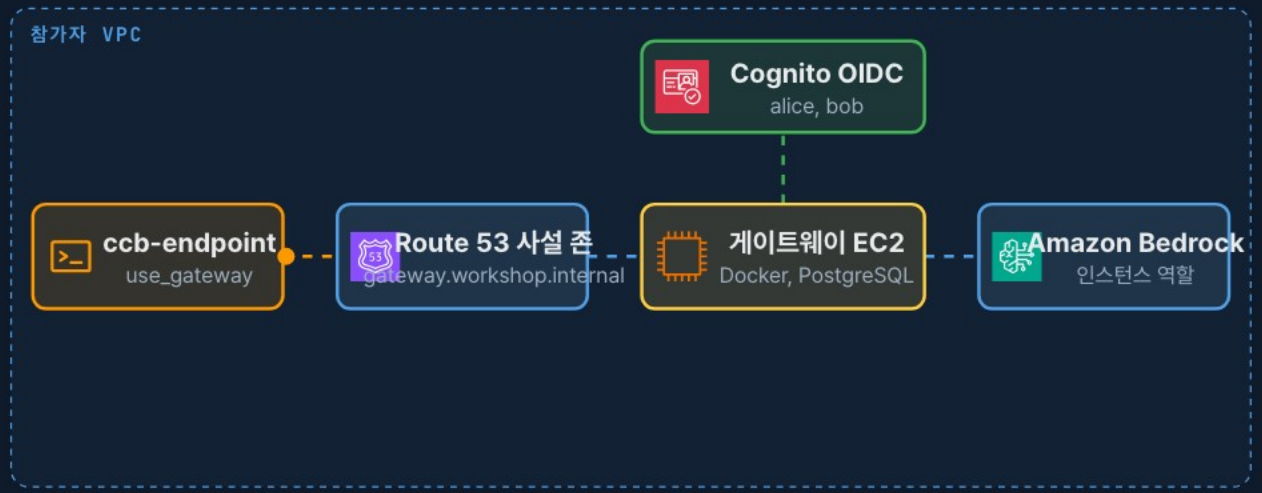
© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Bedrock 앞단의 게이트웨이

Claude Apps Gateway, 공식 구성과 이번 랩 구성

LAB 이번 랩 전용 구성: 계정마다 VPC 안에 한 대

랩에서는 참가자 계정마다 VPC(AWS 안의 사설 네트워크) 안에 게이트웨이가 한 대 있습니다. 로그인 브라우저만 **CloudFront에서 ccb-endpoint nginx**로 노출하고, 게이트웨이는 VPC CIDR(그 네트워크의 IP 주소 범위)만 허용합니다. 운영 환경은 사설망 전용입니다.



● 개발자 ● 네트워크와 Bedrock ● 게이트웨이 ● IdP ● 텔레메트리 중계

ALB ECS Fargate RDS Bedrock Route 53 Cognito CloudFront

랩 토폴로지

TASK 02, 03

```
use_gateway
# managed settings에 forceLoginGatewayUrl
# gateway.workshop.internal (자체 서명 TLS,
trust 확인)
use_bedrock_direct    # 실습 끝나면 원복
```

각자 계정의 게이트웨이로 실습합니다.

- ccb-endpoint(참가자 실습 PC): use_gateway(모드 전환 스크립트)로 managed settings에 forceLoginGatewayUrl
- gateway.workshop.internal, 자체 서명 TLS(전송 암호화 인증서)
- 게이트웨이 EC2: Docker, PostgreSQL, Cognito OIDC (alice, bob)
- Bedrock: 인스턴스 역할, us-east-1, global 추론 프로필의 5.5 모델

‹ 6 / 6 ›

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

사용자별 지출 한도를 실시간으로

지출 한도의 범위, 기간, 초과 시 동작



한도 도달. 다음 요청은 `429 billing_error` 와 리셋 시각을 받습니다.

한도 대비 사용액은 설명용 예시입니다.

범위	user (OIDC sub), rbac_group, organization 그룹, 조직 한도는 1인당 기본값
기간	daily, weekly, monthly (UTC 기준 리셋) 기간별로 각각 적용
초과 시	429 billing_error + 리셋 시각 75%, 95%에서 사전 경고
단가	pricing.overrides, 목록가, 미지 모델 $5/$25 순 추정치, 정산은 AWS
설정	Admin API POST /v1/organizations/spend_limits gateway.yaml이 아님

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

운영 전에 정할 두 가지

기본값이 금융권 기대와 다를 수 있습니다

저장소 장애 시

설정 바꿔 보기 `fail_closed_on_error: true`

저장소 장애 중에는 요청을 차단합니다. 지출은 지켜지지만 추론이 멈춥니다.

- 기본은 fail-open: 요청 통과, 경고 로그
- enforcement.fail_closed_on_error: true면 차단
- 추론 중단과 미계측 지출 중 선택

개인정보

- principal_emails 테이블에 이메일, 이름, 그룹 저장
- 기본 90일 보존 (identity_retention_days)
- 퇴사, 열람 요청 시 해당 행 삭제
- spend, audit은 OIDC sub만 참조

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

그룹 한도와 사용자 한도, 누가 이기나

QUICK CHECK, 손을 들어 답해 주세요

standard-users 그룹 한도가 $50/일인데 bob에게만 1센트 사용자 한도를 걸면?

A 그룹 한도 $50이 우선한다

B 사용자 한도가 우선해 다음 요청부터 429로 막힌다

C 진행 중인 응답까지 즉시 끊긴다

정답 B. 사용자 한도가 그룹 기본값보다 우선합니다. 진행 중인 응답은 끝까지 갑니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

텔레메트리는 어디로 가는가

LAB, Chapter 6 TASK 01

1	settings.json의 OTEL_* 환경 변수 읽기
2	otelcol, fanout 타이머 active 확인
3	scrub_logs: 내보내기 전 프롬프트 본문 삭제 규칙 찾기
4	exporters에서 CloudWatch + 중앙 대시보드 이중 전송 확인

Hands-on Lab 포털에서 Chapter 6 TASK 01을 엽니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

모델 정책과 지출 한도

LAB, 게이트웨이 실습 Chapter 6 TASK 02부터 03까지

1	use_gateway, alice 로그인, /model에 Opus 포함, /usage Spend limit 확인
2	bob으로 재로그인, Opus 없음, 질문 1개로 지출 기록
3	Terminal 2: Admin API로 bob 조회, 사용자 한도 1센트
4	bob 다음 요청이 지출 한도 메시지로 거절
5	한도 DELETE, 그룹 한도 복원, use_bedrock_direct

각자 계정의 게이트웨이로 진행합니다. Hands-on Lab 포털, Chapter 6 TASK 02부터 03. 게이트웨이 장애 팀은 강사 화면을 봅니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

내 계정에 비용 설정 적용

선택 LAB, Chapter 6 선택 TASK 04

1	managed settings에 modelPricing.multiplier 병합
2	/usage에서 configured rates 표시 확인
3	대시보드에서 적용 전후 내 사용량 비교
4	백업으로 원복

각자 Bedrock 직결로 진행합니다. Hands-on Lab 포털, Chapter 6 선택 TASK 04.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

자주 받는 질문

더 알아보기, OTel 지표, 이상 징후, Admin API

1
OTel 지표 모음

2
이상 징후 패턴

3
Admin API로 한도 운영

그룹 기본값 + 예외 사용자

```
# 그룹 기본값: standard-users 1인당 하루 $50
curl -X POST "$GW/v1/organizations/spend_limits" \
  -H "x-api-key: $WRITE" \
  -H "Content-Type: application/json" \
  -d '{"scope":{"type":"rbac_group",
              "rbac_group_id":"standard-users"},
       "amount":"5000","period":"daily"}'
# 현재 적용 한도와 사용액
curl -G "$GW/v1/organizations/spend_limits/effective" \
  --data-urlencode 'period[]=daily' -H "x-api-key: $READ"
```

amount는 US 센트 문자열입니다. 그룹 한도는 공유 풀이 아닌 1인당 기본값이고, 사용자 한도가 그룹보다 우선합니다. write 키는 소수만, 비밀 저장소에 보관합니다.

aws © 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

보고, 막기

Chapter 6 Key Takeaways

01

Bedrock은 Analytics가 없다.
OTel을 정책으로 켠다

02

modelPricing으로 계약 단가 표시,
정산은 AWS와 대사

03

게이트웨이: SSO, 그룹 정책, 지출 한도, 사설망 전용

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Thank You

다음은 Capstone 쇼케이스와 Closing입니다. 질문은 Slack #20261116-claude-code-workshop-for-fsi 채널에 언제든 편하게 남겨 주세요.

수고하셨습니다!

← 목차로 돌아가기

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved.